
LAPORAN
UJIAN AKHIR SEMESTER (UAS)
OBESITY / HEALTH CATEGORY CLASSIFIER

Disusun untuk Memenuhi Tugas Akhir
Mata Kuliah Pemrograman Kecerdasan Buatan (AIB02)



Disusun Oleh:
Josua Nathanael Dharmawan (38250005)

Fakultas Teknologi dan Desain
Program Studi Kecerdasan Buatan
Mata Kuliah Kecerdasan Buatan
Universitas Bunda Mulia
Kampus Serpong
2024/2025

KATA PENGANTAR

Puji syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa atas segala rahmat dan karunia-Nya sehingga laporan Ujian Akhir Semester (UAS) mata kuliah Pemrograman Kecerdasan Buatan (AIB02) yang berjudul "Obesity / Health Category Classifier" ini dapat diselesaikan dengan baik dan tepat waktu.

Laporan ini disusun untuk mendokumentasikan seluruh proses pengerjaan proyek individu berupa sistem klasifikasi kategori berat badan berbasis Artificial Neural Network (MLP) dengan antarmuka aplikasi menggunakan Streamlit. Sebagai inovasi tambahan, sistem juga dilengkapi dengan fitur analisis wajah menggunakan Computer Vision (OpenCV) sebagai mode input alternatif.

Penulis menyadari bahwa laporan ini masih jauh dari sempurna. Oleh karena itu, penulis mengharapkan kritik dan saran yang membangun dari dosen pengampu demi perbaikan di masa yang akan datang.

Akhir kata, penulis mengucapkan terima kasih kepada dosen pengampu mata kuliah AIB02 yang telah memberikan bimbingan dan arahan selama proses pengerjaan proyek ini.

Serpong, Mei 2025

Penulis,

Josua Nathanael Dharmawan

DAFTAR ISI

Halaman Judul	i
Kata Pengantar	ii
Daftar Isi	iii
BAB I PENDAHULUAN	
1.1 Masalah yang Ingin Diselesaikan	5
1.2 Latar Belakang	5
1.3 Target Pengguna Sistem	6
1.4 Manfaat Sistem	6
1.5 Input dan Output Sistem	7
1.6 Alasan Memilih Metode ANN/MLP	7
BAB II DATASET	
2.1 Informasi Dataset	9
2.2 Fitur / Atribut yang Digunakan	10
2.3 Target / Label	11
BAB III TAHAPAN Pengerjaan	
3.1 Load Dataset	12
3.2 Preprocessing Data	12
3.3 Pembagian Data Train / Test	13
3.4 Pembuatan Model	13
3.5 Training Model	14
3.6 Evaluasi	14
3.7 Penyimpanan Model	14

3.8	Integrasi ke Aplikasi Streamlit	15
BAB IV HASIL DAN EVALUASI		
4.1	Akurasi Model	16
4.2	Classification Report per Kelas	16
4.3	Contoh Hasil Prediksi	17
4.4	Fitur Computer Vision — Face Scan	18
BAB V TAMPILAN SISTEM / APLIKASI		
5.1	Deskripsi Antarmuka	19
5.2	Komponen Aplikasi	19
5.3	Cara Menjalankan Aplikasi	20
5.4	Alur Penggunaan	21
BAB VI KESIMPULAN		
6.1	Keberhasilan Sistem	22
6.2	Kesesuaian Hasil	22
6.3	Kendala yang Dialami	23
6.4	Saran Pengembangan	23
Daftar Pustaka		25

BAB I

PENDAHULUAN

1.1 Masalah yang Ingin Diselesaikan

Obesitas merupakan salah satu masalah kesehatan global yang terus meningkat pesat. Penentuan kategori berat badan seseorang umumnya memerlukan pengukuran tinggi dan berat badan secara manual menggunakan alat ukur fisik, yang tidak selalu tersedia atau praktis di berbagai kondisi. Di sisi lain, kebiasaan makan, tingkat aktivitas fisik, dan faktor lingkungan turut berkontribusi terhadap kondisi berat badan seseorang, yang tidak dapat ditangkap hanya dari pengukuran BMI semata.

Proyek ini bertujuan membangun sistem klasifikasi otomatis yang mampu memprediksi kategori berat badan seseorang — mulai dari berat badan kurang hingga obesitas tipe III — berdasarkan kombinasi fitur kebiasaan makan, kondisi fisik, dan gaya hidup menggunakan Artificial Neural Network (MLP). Sebagai inovasi tambahan, sistem juga dilengkapi mode input alternatif berbasis Computer Vision yang mengekstrak fitur geometri wajah sebagai estimasi kondisi tubuh.

1.2 Latar Belakang

Klasifikasi tingkat obesitas selama ini hanya mengandalkan indeks massa tubuh ($BMI = \text{berat} / \text{tinggi}^2$) yang membutuhkan alat ukur fisik. Padahal, penelitian di bidang kesehatan menunjukkan bahwa pola makan, aktivitas fisik, riwayat keluarga, dan gaya

hidup merupakan faktor-faktor yang secara kolektif menentukan kategori berat badan seseorang dengan lebih komprehensif.

Di sisi lain, penelitian terkini di bidang Computer Vision (Wen & Guo, 2013; Kocabey et al., 2017; Jiang et al., 2019) telah membuktikan adanya korelasi yang signifikan antara rasio geometri wajah — seperti Face Aspect Ratio (FAR) dan Eye Span Ratio — dengan nilai BMI seseorang. Temuan ini membuka peluang untuk menggunakan analisis wajah sebagai cara estimasi awal kategori berat badan hanya dari sebuah foto, meskipun dengan akurasi yang bersifat estimatif.

1.3 Target Pengguna Sistem

Adapun target pengguna dari sistem yang dikembangkan dalam proyek ini adalah sebagai berikut:

1. Individu umum yang ingin mengetahui estimasi kategori berat badan berdasarkan kebiasaan hidup tanpa perlu alat ukur.
2. Tenaga kesehatan atau kader posyandu yang membutuhkan alat skrining awal yang cepat dan mudah digunakan.
3. Peneliti atau mahasiswa yang mempelajari aplikasi Artificial Neural Network pada data kesehatan tabular.

1.4 Manfaat Sistem

Sistem yang dikembangkan dalam proyek ini diharapkan dapat memberikan manfaat sebagai berikut:

1. Memberikan estimasi kategori berat badan secara cepat dan mudah diakses tanpa memerlukan peralatan khusus.

-
2. Meningkatkan kesadaran masyarakat terhadap risiko obesitas berdasarkan kebiasaan dan gaya hidup sehari-hari.
 3. Menyediakan tampilan probabilitas per kategori untuk interpretasi yang lebih informatif dan edukatif.
 4. Menjadi proof-of-concept penggunaan Computer Vision sebagai alternatif input pada sistem klasifikasi kesehatan.

1.5 Input dan Output Sistem

Sistem memiliki dua mode input sebagai berikut:

a. Input Mode 1 (Input Manual): Pengguna mengisi 16 fitur tabular yang meliputi jenis kelamin, usia, tinggi badan, berat badan, kebiasaan makan, frekuensi aktivitas fisik, konsumsi air, dan gaya hidup lainnya melalui form interaktif Streamlit.

b. Input Mode 2 (Face Scan): Pengguna mengupload foto wajah frontal yang kemudian diproses menggunakan OpenCV Haarcascade untuk mendeteksi wajah dan mengekstrak fitur geometri (FAR, Eye Span Ratio, Eye Width Ratio, Adiposity Score) sebagai estimasi fitur input tabular.

Output Sistem: Label kategori berat badan (7 kelas), nilai confidence prediksi, estimasi BMI, dan distribusi probabilitas untuk seluruh kelas yang tersedia.

1.6 Alasan Memilih Metode ANN/MLP

Metode Artificial Neural Network dengan arsitektur Multilayer Perceptron (MLP) dipilih dengan pertimbangan-pertimbangan sebagai berikut:

1. MLP mampu mempelajari pola non-linear yang kompleks dari kombinasi fitur tabular heterogen (campuran numerik dan kategorikal).

-
2. Lebih fleksibel dibandingkan decision tree atau SVM untuk masalah klasifikasi dengan banyak kelas (7 kelas).
 3. MLPClassifier dari library scikit-learn efisien secara komputasi, mendukung mekanisme early stopping untuk mencegah overfitting, dan mudah diintegrasikan ke dalam aplikasi.
 4. Telah terbukti dalam berbagai penelitian di bidang health informatics mencapai akurasi tinggi pada dataset kesehatan yang serupa.

BAB II

DATASET

2.1 Informasi Dataset

Dataset yang digunakan dalam proyek ini adalah dataset publik yang tersedia di UCI Machine Learning Repository dan Kaggle dengan informasi sebagai berikut:

Atribut	Keterangan
Nama Dataset	Estimation of Obesity Levels Based on Eating Habits and Physical Condition
Sumber	UCI Machine Learning Repository / Kaggle
Link	kaggle.com/datasets/fatemehmehrpavar/obesity-levels
Jumlah Data	2.111 baris
Jumlah Fitur	16 fitur input + 1 kolom target
Jenis Tugas	Klasifikasi Tabular Multi-kelas (7 kelas)
Format File	CSV — ObesityDataSet_raw_and_data_synthetic.csv

Dataset ini dikembangkan oleh Palechor & de la Hoz Manotas (2019) dan berisi data dari individu di Kolombia, Peru, dan Meksiko. Sebagian data merupakan data sintetis yang dibangkitkan menggunakan teknik SMOTE (Synthetic Minority Over-sampling Technique) untuk menyeimbangkan distribusi kelas.

2.2 Fitur / Atribut yang Digunakan

Berikut adalah 16 fitur input yang digunakan sebagai variabel prediktor dalam model:

No	Nama Fitur	Tipe Data	Deskripsi
1	Gender	Kategorikal	Jenis kelamin responden (Male/Female)
2	Age	Numerik	Usia responden dalam satuan tahun
3	Height	Numerik	Tinggi badan dalam satuan meter
4	Weight	Numerik	Berat badan dalam satuan kilogram
5	family_history_with_overweight	Kategorikal	Riwayat kegemukan dalam keluarga (yes/no)
6	FAVC	Kategorikal	Sering mengonsumsi makanan berkalori tinggi (yes/no)
7	FCVC	Numerik	Frekuensi konsumsi sayuran (skala 1–3)
8	NCP	Numerik	Jumlah makan utama per hari (skala 1–4)
9	CAEC	Kategorikal	Konsumsi makanan di luar waktu makan utama
10	SMOKE	Kategorikal	Status merokok (yes/no)
11	CH2O	Numerik	Jumlah konsumsi air per hari dalam liter (1–3)
12	SCC	Kategorikal	Pemantauan kalori harian (yes/no)
13	FAF	Numerik	Frekuensi aktivitas fisik per minggu (skala 0–3)
14	TUE	Numerik	Waktu penggunaan perangkat teknologi per hari (0–2)
15	CALC	Kategorikal	Frekuensi konsumsi alkohol
16	MTRANS	Kategorikal	Moda transportasi utama yang digunakan

2.3 Target / Label

Variabel target dalam dataset ini adalah kolom NObeyesdad yang terdiri dari 7 kelas kategori berat badan sebagai berikut:

Label	Keterangan	Rentang BMI	Jumlah Data
Insufficient_Weight	Berat Badan Kurang	< 18,5	272 data
Normal_Weight	Berat Badan Normal	18,5 – 24,9	287 data
Overweight_Level_I	Kegemukan Tingkat I	25,0 – 27,4	290 data
Overweight_Level_II	Kegemukan Tingkat II	27,5 – 29,9	290 data
Obesity_Type_I	Obesitas Tipe I	30,0 – 34,9	351 data
Obesity_Type_II	Obesitas Tipe II	35,0 – 39,9	297 data
Obesity_Type_III	Obesitas Tipe III (Morbid)	>= 40,0	324 data
Total	—	—	2.111 data

BAB III

TAHAPAN Pengerjaan

3.1 Load Dataset

Dataset dimuat ke dalam Python menggunakan library pandas dari file CSV yang disertakan bersama proyek. Data yang berhasil dimuat terdiri dari 2.111 baris dan 17 kolom (16 fitur prediktor dan 1 kolom target). Proses loading dilakukan dengan perintah berikut:

```
df = pd.read_csv("ObesityDataSet_raw_and_data_synthetic.csv")
```

Hasil pemeriksaan awal menunjukkan bahwa dataset tidak memiliki missing values dan distribusi antar kelas cukup seimbang (272 hingga 351 data per kelas), sehingga tidak diperlukan teknik oversampling tambahan.

3.2 Preprocessing Data

Tahap preprocessing meliputi beberapa langkah berikut:

1. Pemisahan fitur dan target: kolom NObeyesdad dipisahkan sebagai variabel target (y), sementara 16 kolom sisanya menjadi fitur prediktor (X).
2. Label Encoding: delapan kolom kategorikal (Gender, FAVC, CAEC, SMOKE, SCC, CALC, MTRANS, dan family_history_with_overweight) dikonversi menjadi nilai numerik menggunakan LabelEncoder dari scikit-learn. Setiap encoder disimpan untuk digunakan kembali saat prediksi.
3. Target Encoding: variabel target dengan 7 kelas teks dikonversi menjadi nilai integer menggunakan LabelEncoder yang terpisah.

-
4. Standarisasi Fitur: seluruh fitur numerik distandarisasi menggunakan StandardScaler agar memiliki skala yang seragam, yang penting untuk mempercepat konvergensi algoritma gradient descent pada MLP.

3.3 Pembagian Data Train / Test

Dataset dibagi menjadi dua bagian: 80% untuk data training dan 20% untuk data testing. Pembagian dilakukan dengan stratified split untuk memastikan proporsi setiap kelas terjaga dengan baik di kedua subset.

Set Data	Jumlah Data	Proporsi
Training Set	1.688 data	80%
Testing Set	423 data	20%
Total	2.111 data	100%

3.4 Pembuatan Model

Model yang digunakan adalah MLPClassifier (Multilayer Perceptron) dari library scikit-learn. Arsitektur dan konfigurasi hyperparameter model adalah sebagai berikut:

Parameter	Nilai	Keterangan
hidden_layer_sizes	(128, 64, 32)	3 hidden layer dengan 128, 64, dan 32 neuron
activation	relu	Fungsi aktivasi ReLU pada setiap hidden layer
solver	adam	Optimizer Adam — adaptif dan efisien untuk data berukuran sedang
max_iter	500	Batas maksimum 500 iterasi training
early_stopping	True	Menghentikan training jika tidak ada peningkatan pada validation

Parameter	Nilai	Keterangan
validation_fraction	0.1	10% dari data training digunakan sebagai data validasi internal
n_iter_no_change	20	Toleransi 20 iterasi tanpa peningkatan sebelum training dihentikan
random_state	42	Nilai seed untuk reproducibility hasil training

3.5 Training Model

Model dilatih menggunakan data training yang telah distandarisasi. Proses training berjalan selama 66 iterasi sebelum mekanisme early stopping aktif, karena nilai loss pada data validasi tidak mengalami penurunan yang signifikan selama 20 iterasi berturut-turut. Hal ini menandakan bahwa model telah konvergen tanpa mengalami overfitting.

3.6 Evaluasi

Model dievaluasi menggunakan 423 data testing yang sepenuhnya terpisah dari proses training. Metrik evaluasi yang digunakan meliputi accuracy keseluruhan, serta precision, recall, dan F1-score untuk setiap kelas secara individual.

3.7 Penyimpanan Model

Seluruh artefak yang diperlukan untuk menjalankan prediksi disimpan ke dalam folder model/ menggunakan library joblib, sehingga aplikasi Streamlit tidak perlu melakukan training ulang setiap kali dijalankan. Artefak yang disimpan meliputi:

1. model/mlp_obesity.pkl — Model MLPClassifier yang telah dilatih.
2. model/scaler.pkl — StandardScaler yang telah di-fit pada data training.
3. model/label_encoder_target.pkl — LabelEncoder untuk variabel target.

-
4. `model/label_encoders_features.pkl` — LabelEncoder untuk setiap fitur kategorikal.
 5. `model/feature_cols.pkl` — Daftar nama kolom fitur beserta urutannya.

3.8 Integrasi ke Aplikasi Streamlit

Seluruh artefak model yang tersimpan kemudian diintegrasikan ke dalam aplikasi web sederhana menggunakan framework Streamlit (`app.py`). Aplikasi menyediakan dua mode input yang dapat dipilih pengguna:

a. Mode Input Manual: Pengguna mengisi form yang terdiri dari 16 fitur melalui widget interaktif Streamlit seperti `selectbox`, `slider`, dan `number_input`. Setelah tombol prediksi ditekan, data diproses menggunakan encoder dan scaler yang tersimpan sebelum dimasukkan ke model MLP.

b. Mode Face Scan (Computer Vision): Pengguna mengupload foto wajah yang kemudian dianalisis menggunakan OpenCV Haarcascade untuk mendeteksi wajah dan mata, lalu mengekstrak fitur geometri wajah. Fitur-fitur tersebut dipetakan ke format input tabular sebelum diproses oleh model MLP yang sama.

Alur pipeline mode Face Scan secara ringkas adalah sebagai berikut: Upload Foto → Deteksi Wajah & Mata (OpenCV) → Ekstraksi Fitur Geometri → Pemetaan ke Fitur Tabular → Prediksi MLP → Output Kategori.

BAB IV

HASIL DAN EVALUASI

4.1 Akurasi Model

Hasil evaluasi model MLPClassifier pada data testing menunjukkan performa yang sangat baik, sebagaimana ditampilkan dalam tabel berikut:

Metrik Evaluasi	Nilai
Accuracy keseluruhan	94,09%
Macro Average Precision	94%
Macro Average Recall	94%
Macro Average F1-Score	94%
Weighted Average F1-Score	94%
Jumlah data testing	423 data
Jumlah iterasi training	66 iterasi (early stopping aktif)

4.2 Classification Report per Kelas

Berikut adalah rincian metrik evaluasi untuk setiap kelas kategori berat badan:

Kelas	Precision	Recall	F1-Score	Support
Insufficient_Weight	0,95	0,98	0,96	54
Normal_Weight	0,92	0,81	0,86	58
Overweight_Level_I	0,84	0,93	0,89	58

Kelas	Precision	Recall	F1-Score	Support
Overweight_Level_II	0,96	0,90	0,93	58
Obesity_Type_I	0,96	0,99	0,97	70
Obesity_Type_II	0,97	0,98	0,98	60
Obesity_Type_III	0,98	0,98	0,98	65
Weighted Average	0,94	0,94	0,94	423

Dari tabel di atas terlihat bahwa model menunjukkan performa yang sangat baik di hampir semua kelas. Kelas Normal_Weight memiliki F1-score terendah (0,86) yang dapat dipahami karena batas antara Normal_Weight dan Overweight_Level_I secara klinis relatif tipis. Sebaliknya, kelas Obesity_Type_II dan Obesity_Type_III mencapai F1-score tertinggi sebesar 0,98, menunjukkan kemampuan model yang sangat kuat dalam mengenali kasus-kasus obesitas tingkat lanjut.

4.3 Contoh Hasil Prediksi

Berikut adalah contoh hasil prediksi model pada 5 data pertama dari data testing:

No	Label Aktual	Label Prediksi	Keterangan
1	Insufficient_Weight	Insufficient_Weight	Benar
2	Normal_Weight	Normal_Weight	Benar
3	Overweight_Level_II	Overweight_Level_II	Benar
4	Obesity_Type_III	Obesity_Type_III	Benar
5	Obesity_Type_II	Obesity_Type_II	Benar

4.4 Fitur Computer Vision — Mode Face Scan

Sebagai inovasi tambahan pada sistem ini, mode Face Scan memanfaatkan OpenCV Haarcascade untuk mendeteksi wajah dari foto yang diupload, kemudian mengekstrak fitur-fitur geometri wajah berikut:

Fitur	Definisi	Dasar Ilmiah
FAR (Face Aspect Ratio)	Rasio lebar terhadap tinggi bounding box wajah	Wajah lebih lebar (FAR tinggi) berkorelasi dengan BMI yang lebih tinggi (Kocabey et al., 2017)
Eye Span Ratio	Jarak antar pusat kedua mata dibagi lebar wajah	Rasio lebih kecil mengindikasikan wajah lebih bulat (Wen & Guo, 2013)
Eye Width Ratio	Rata-rata lebar mata dibagi lebar wajah	Nilai lebih kecil mengindikasikan distribusi lemak wajah lebih besar
Adiposity Score	Skor gabungan estimasi lemak wajah (0–100%)	Dihitung dari weighted combination FAR, Eye Span, dan Eye Width Ratio

Fitur-fitur geometri yang diekstrak kemudian dipetakan ke format input tabular menggunakan fungsi heuristik berbasis korelasi yang berasal dari literatur ilmiah, sebelum akhirnya diproses oleh model MLP yang sama dengan mode input manual.

BAB V

TAMPILAN SISTEM / APLIKASI

5.1 Deskripsi Antarmuka

Aplikasi dibangun menggunakan framework Streamlit versi terkini dan dapat dijalankan secara lokal melalui perintah `streamlit run app.py`. Tampilan antarmuka terdiri dari header judul dengan ikon , deskripsi singkat sistem, dan dua tab mode input yang dapat dipilih pengguna secara bebas.

Aplikasi telah memenuhi seluruh komponen minimal yang ditetapkan, yaitu: (1) judul sistem yang jelas, (2) form input untuk memasukkan data, (3) tombol untuk memproses prediksi, dan (4) tampilan hasil keluaran berupa label kategori, confidence, dan distribusi probabilitas.

5.2 Komponen Aplikasi

Berikut adalah komponen-komponen yang terdapat dalam antarmuka aplikasi:

Komponen	Deskripsi	Lokasi
Judul	Obesity Health Category Classifier dengan ikon 	Header utama halaman
Deskripsi Sistem	Penjelasan singkat mengenai dua mode input yang tersedia	Di bawah judul
Tab 1 — Input Manual	Form 16 fitur: widget selectbox, slider, dan <code>number_input</code>	Tab kiri

Komponen	Deskripsi	Lokasi
Tab 2 — Face Scan	Form data dasar + area upload foto + penjelasan fitur CV	Tab kanan
Indikator BMI	Menampilkan nilai BMI yang dihitung secara real-time dari input	Tab Input Manual
Tombol Prediksi	Primary button berwarna biru untuk memulai proses prediksi	Setiap tab
Kotak Hasil Prediksi	Menampilkan label kategori dengan confidence % dan BMI	Muncul setelah klik prediksi
Bar Probabilitas	Bar chart horizontal probabilitas untuk 7 kelas sekaligus	Di bawah kotak hasil
Adiposity Score Bar	Progress bar visual skor estimasi lemak wajah (0–100%)	Tab Face Scan
Metric Cards	4 kartu metrik: FAR, Eye Span Ratio, Eye Width Ratio, Adiposity	Tab Face Scan
Annotated Image	Foto wajah dengan bounding box deteksi + label FAR & Adiposity	Tab Face Scan
Disclaimer Ilmiah	Catatan akurasi estimasi wajah beserta referensi ilmiah	Setelah prediksi Face Scan
Footer	Informasi model, dataset, dan akurasi sistem	Bagian bawah halaman

5.3 Cara Menjalankan Aplikasi

Berikut adalah langkah-langkah untuk menjalankan aplikasi secara lokal:

1. Install seluruh dependencies yang dibutuhkan:

```
pip install streamlit scikit-learn pandas numpy joblib  
opencv-python
```

2. Jalankan script training untuk membuat folder model/ beserta seluruh artefak (hanya perlu dilakukan sekali):

```
python Project_UAS_Josua_Nathanael_Dharmawan_38250005.py
```

3. Jalankan aplikasi Streamlit:

```
streamlit run app.py
```

-
4. Buka browser dan akses aplikasi di alamat: <http://localhost:8501>

5.4 Alur Penggunaan

Alur penggunaan untuk masing-masing mode input adalah sebagai berikut:

Mode Input Manual:

5. Pilih tab "Input Manual" pada bagian atas halaman aplikasi.
6. Isi seluruh 16 form input sesuai dengan kondisi dan kebiasaan harian pengguna.
7. Amati indikator BMI yang dihitung otomatis berdasarkan tinggi dan berat badan yang dimasukkan.
8. Tekan tombol "Prediksi Sekarang" untuk menjalankan prediksi.
9. Lihat hasil prediksi berupa kategori, confidence, nilai BMI, dan distribusi probabilitas 7 kelas.

Mode Face Scan:

1. Pilih tab "Face Scan (Computer Vision)" pada bagian atas halaman aplikasi.
2. Isi data dasar: jenis kelamin, usia, dan tinggi badan.
3. (Opsional) Aktifkan toggle dan masukkan berat badan aktual untuk meningkatkan akurasi prediksi.
4. Upload foto wajah frontal dalam format JPG atau PNG. Sistem secara otomatis akan mendeteksi wajah dan menampilkan fitur geometri beserta annotated image.
5. Tekan tombol "Prediksi Kategori Obesitas dari Wajah" untuk menjalankan prediksi.
6. Lihat hasil prediksi, adiposity score bar, dan distribusi probabilitas 7 kelas.

BAB VI

KESIMPULAN

6.1 Keberhasilan Sistem

Sistem berhasil dijalankan secara lokal menggunakan framework Streamlit. Kedua mode input — Input Manual dan Face Scan — berfungsi dengan baik sesuai yang direncanakan. Model MLPClassifier berhasil dilatih, disimpan dalam format joblib, dan diintegrasikan ke dalam aplikasi tanpa hambatan teknis yang berarti.

6.2 Kesesuaian Hasil

Hasil evaluasi model melampaui ekspektasi awal. Akurasi sebesar 94,09% pada data testing yang sepenuhnya terpisah menunjukkan bahwa model MLP dengan arsitektur tiga hidden layer (128-64-32) mampu mempelajari pola kompleks dari kombinasi fitur gaya hidup dengan sangat baik. Seluruh kelas mencapai F1-score minimal 0,86, dengan rata-rata weighted F1-score sebesar 0,94.

Model berhasil mempelajari pola yang bermakna dari data, bukan sekadar menghafal, terbukti dari konsistensi performa yang tinggi pada data testing yang tidak pernah dilihat selama training. Mekanisme early stopping juga berjalan efektif, menghentikan training pada iterasi ke-66 dari batas maksimum 500 iterasi.

6.3 Kendala yang Dialami

Beberapa kendala yang ditemui selama pengerjaan proyek ini adalah sebagai berikut:

4. Keterbatasan dataset foto wajah berlabel BMI yang bersifat publik dan bebas digunakan. Tidak tersedianya dataset face-to-BMI yang terbuka mengharuskan mode Face Scan menggunakan pendekatan heuristik berbasis korelasi dari literatur ilmiah, alih-alih model CNN yang dilatih secara langsung.
5. Library MediaPipe versi terbaru (0.10.x) tidak lagi menyertakan Solutions API dan memerlukan file model eksternal (.task) yang tidak dapat diunduh dari lingkungan pengembangan yang dibatasi jaringannya. Hal ini mengharuskan migrasi implementasi ke OpenCV Haarcascade yang lebih portabel dan tidak memerlukan file model eksternal.
6. Akurasi mode Face Scan secara inheren lebih rendah dibandingkan mode Input Manual, karena estimasi fitur gaya hidup dari geometri wajah bersifat heuristik dan tidak dapat mencerminkan kondisi aktual pengguna.

6.4 Saran Pengembangan

Berdasarkan evaluasi dan kendala yang dialami, beberapa saran pengembangan untuk ke depannya adalah sebagai berikut:

7. Mengumpulkan atau menggunakan dataset foto wajah berlabel BMI yang tervalidasi (seperti FIW-BMI atau VIP-Attribute) untuk melatih model CNN atau ResNet50 yang khusus memprediksi BMI dari wajah, guna menggantikan pendekatan heuristik yang saat ini digunakan.

-
8. Menambahkan fitur tracking progres agar pengguna dapat memantau perkembangan kategori berat badan dari waktu ke waktu secara historis.
 9. Melakukan deployment ke platform cloud seperti Streamlit Cloud atau Hugging Face Spaces agar aplikasi dapat diakses tanpa perlu instalasi lokal.
 10. Menambahkan fitur rekomendasi pola hidup sehat yang dipersonalisasi berdasarkan kategori yang diprediksi, sehingga sistem tidak hanya bersifat diagnostik tetapi juga edukatif dan preventif.

DAFTAR PUSTAKA

Kocabey, E., Camurcu, M., Ofli, F., Aytar, Y., Marin, J., Torralba, A., & Weber, I. (2017). Face-to-BMI: Using Computer Vision to Infer Body Mass Index on Social Media. 11th International AAAI Conference on Web and Social Media.

Palechor, F. M., & de la Hoz Manotas, A. (2019). Dataset for estimation of obesity levels based on eating habits and physical condition in individuals from Colombia, Peru and Mexico. *Data in Brief*, 25, 104344.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, E. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.

Russell, S. J., & Norvig, P. (2020). *Artificial Intelligence: A Modern Approach*. Edisi ke-4. New Jersey: Pearson Education.

Viola, P., & Jones, M. (2001). Rapid Object Detection using a Boosted Cascade of Simple Features. *Proceedings of the 2001 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, Vol. 1, pp. 511–518.

Wen, Y., & Guo, G. (2013). BMI Estimation from Facial Images Using Computational Approach. *Proceedings of IEEE International Conference on Automatic Face and Gesture Recognition (FG 2013)*.